// MINI CURSO DE SYSTEM DESIGN

Conquistando o primeiro milhão

Um sistema de verdade, uma carga de verdade, e o que muda a cada decisão.



// POR QUE ESTE CURSO

Big O no quadro, e num sistema inteiro?

A TEORIA

Complexidade, estruturas, modelos

É ela que explica por que um sistema aguenta, ou não aguenta.

OS EXEMPLOS

Soltos

Ordenar uma lista, montar uma árvore: corretos, mas sem um sistema em volta.

O OBJETO

Um sistema inteiro

Algo concreto para medir, mudar e medir de novo, à luz da teoria.

Este curso dá à teoria um objeto: uma aplicação que dá para trabalhar.

// O QUE VAMOS VER

A base, e depois um sistema de verdade

PARTE 1

Os conceitos básicos

- Como uma aplicação web funciona
- A requisição HTTP e os códigos de status
- APIs e sistemas que conversam entre si
- O que acontece dentro do servidor
- Banco de dados, o básico
- Como medir: tempo de resposta e vazão
- Teste de carga
- Containers e limites de hardware

PARTE 2

O protótipo

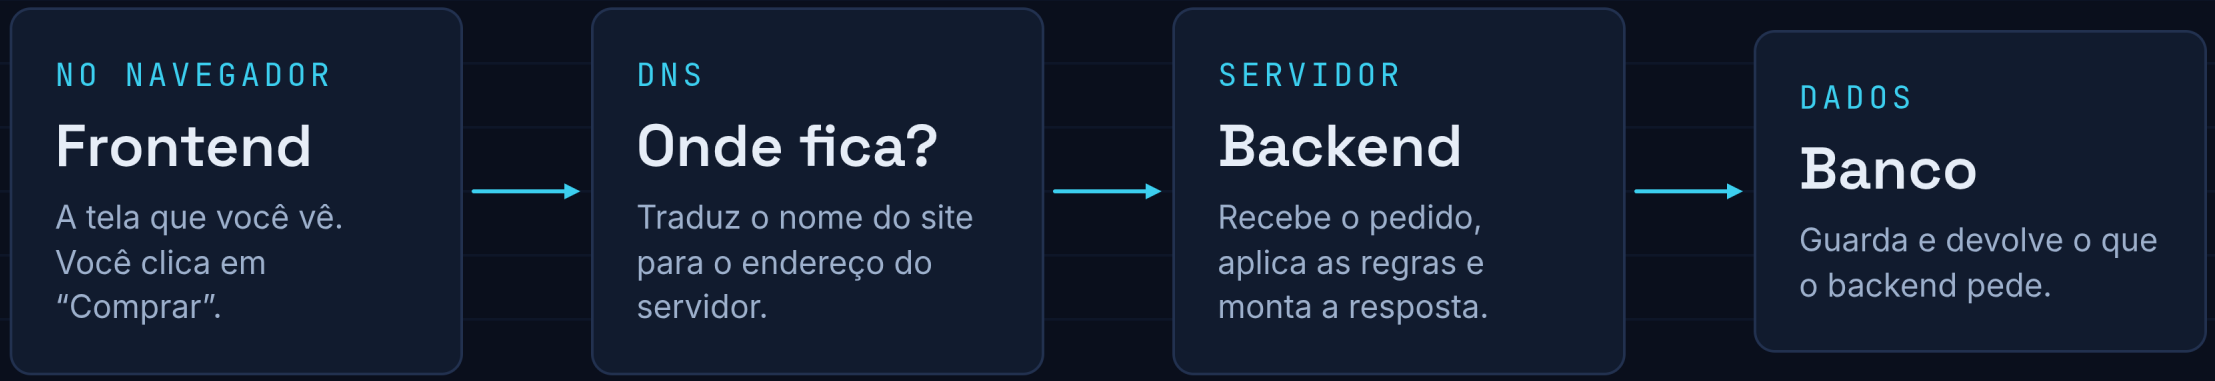
- Um sistema de venda de ingressos
- Uma grande estreia de cinema, simulada
- Uma mudança de cada vez
- Cada mudança testada ao vivo, com números

// PARTE 1 · OS CONCEITOS BÁSICOS

01

Como uma aplicação web funciona

O caminho de um clique



E a resposta faz o caminho de volta até a tela.

Um endereço, em pedaços

https://ingressa.com:443/sessoes/1

PROTOCOLO

HTTP, o protocolo da web. O “s” indica que a conversa é criptografada.

NOME

O DNS troca o nome pelo IP: o endereço do servidor na rede.

PORTA

Qual programa, dentro daquele servidor, vai atender. O https usa a 443.

CAMINHO

O que você quer daquele programa: aqui, a sessão número 1.

Três camadas, três responsabilidades

FRONTEND

O que você vê

Telas, botões e formulários. Roda no navegador de quem usa.

ex: o mapa de assentos

BACKEND

As regras

Decide o que pode e o que não pode. Roda no servidor.

ex: no máximo 6 ingressos por CPF

BANCO DE DADOS

A memória

Guarda os dados de forma permanente e organizada.

ex: a tabela de pedidos

Por que a regra dos 6 ingressos por CPF não pode ficar só no frontend?

// PARTE 1 · OS CONCEITOS BÁSICOS

02

A requisição HTTP

Toda conversa é um pedido e uma resposta

REQUISIÇÃO · O NAVEGADOR PEDE

```
POST /pedidos HTTP/1.1
Host: ingressa.com
Content-Type: application/json

{
  "sessao_id": 1,
  "cpf": "529.982.247-25",
  "itens": [{ "assento": "F7" }]
}
```

RESPOSTA · O SERVIDOR DEVOLVE

```
HTTP/1.1 201 Created
Content-Type: application/json

{
  "id": 42,
  "status": "confirmado",
  "total_centavos": 6600
}
```

O método diz a intenção

GET

Buscar

Só lê. Repetir não muda nada no servidor.

`GET /sessoes/1/assentos`

POST

Criar

Muda alguma coisa: cria um pedido, cobra um cartão.

`POST /pedidos`

PUT · PATCH · DELETE

Mudar e apagar

Atualizar ou remover algo que já existe.

`DELETE /reservas/7`

Se a pessoa clicar duas vezes em “Comprar”, o que acontece?

O código de status resume a resposta

2xx

Deu certo

200 OK

201 Criado

4xx

O problema está no pedido

404 Não encontrado

422 Dados inválidos

5xx

O problema está no servidor

500 Erro interno

O site travou na hora da compra. De qual grupo você espera o código?

// PARTE 1 · OS CONCEITOS BÁSICOS

03

APIs e sistemas que conversam

A API: o que o backend sabe fazer

método	caminho	o que faz
GET	/filmes	a programação
GET	/sessoes/1/assentos	o mapa de assentos
POST	/pedidos	comprar ingressos
GET	/pedidos/42	ver uma compra

Quem usa a API não precisa saber como o backend funciona por dentro: só o que pedir e o que esperar de volta.

O backend também depende de outros

NOSSO SISTEMA

Backend

Para concluir uma compra, precisa deles.

→ **Sistema do cinema** — reserva e confirma os assentos

→ **Gateway de pagamento** — cobra o cartão

→ **Servidor de e-mail** — entrega os ingressos

Se um deles fica lento, o backend fica lento junto.

> Enquanto espera o pagamento, o que o backend está fazendo?

04

O que acontece dentro do servidor

Quatro peças em todo servidor

PROCESSO

O programa rodando

O backend em execução, com a sua parte da memória.

THREAD

Uma linha de execução

Atende uma requisição por vez, do começo ao fim.

CPU

Quem executa

Roda as instruções. Cada núcleo faz uma coisa de cada vez.

MEMÓRIA

Onde os dados ficam

Rápida, mas limitada, e apaga quando o programa para.

// 04 · DENTRO DO SERVIDOR

Trabalhar não é o mesmo que esperar

TRABALHAR · GASTA CPU

Validar o CPF, montar o JSON, gerar o QR code do ingresso.

ESPERAR · NÃO GASTA CPU

O banco responder, o cinema reservar, o gateway cobrar.

UMA COMPRA, DO COMEÇO AO FIM



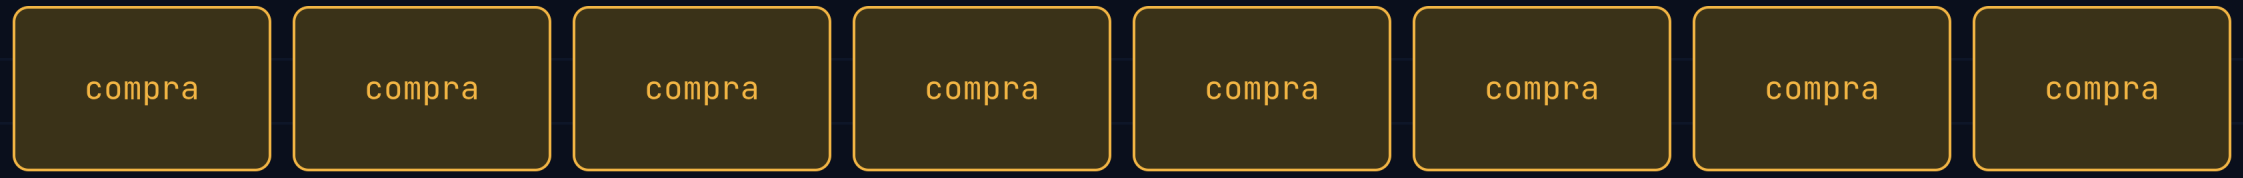
trabalhando esperando outro sistema

Quase todo o tempo é espera, e a thread fica presa junto.

// 04 · DENTRO DO SERVIDOR

Muita gente ao mesmo tempo

AS THREADS DO SERVIDOR



QUEM CHEGA AGORA

ver filmes · ver o mapa · comprar · ver filmes · …

Com todas ocupadas, até quem só quer olhar espera na fila.

> Se cada compra prende uma thread por segundos, quantas cabem por segundo?

05

Banco de dados, o básico

Tabela, consulta e índice

TABELA PEDIDOS

id	sessão	cpf	status
41	1	…247-25	confirmado
42	1	…118-03	aguardando
43	2	…247-25	confirmado

CONSULTA · SQL

```sql
SELECT sum(qtd_ingressos)
FROM pedidos
WHERE sessao_id = 1
  AND cpf = '52998224725'
```

ÍNDICE

Uma estrutura à parte que leva direto às linhas certas. Sem ele, o banco lê a tabela inteira, e ela cresce a cada venda.

// 05 · BANCO DE DADOS

Duas pessoas, o mesmo assento

ANA

1. Vê o F7 livre
2. Clica em “Comprar”
3. Recebe o F7

BRUNO, NO MESMO INSTANTE

1. Vê o F7 livre
2. Clica em “Comprar”
3. Recebe o F7?

TRANSAÇÃO

Um conjunto de passos que acontece inteiro, ou não acontece.

TRAVA

Quem chega depois espera o primeiro terminar: um de cada vez.

06

Como medir

Duas medidas diferentes

LATÊNCIA · TEMPO DE RESPOSTA

Quanto demora

O tempo entre pedir e receber a resposta, para uma requisição.

ms

VAZÃO

Quanto cabe

Quantas requisições o sistema conclui por segundo.

req/s

Um sistema pode ser rápido e aguentar pouco, ou aguentar muito e ser lento.

// 06 · COMO MEDIR

A média esconde quem esperou mais

10 REQUISIÇÕES: 9 LEVARAM 100 MS, 1 LEVOU 5 S

MÉDIA

590 ms

Um tempo que ninguém viveu.

METADE EM ATÉ · P50

100 ms

O caso típico.

95% EM ATÉ · P95

5 s

O que sentem os que esperaram mais.

A Lei de Little

em andamento = por segundo × duração

EXEMPLO

10 compras por segundo, cada uma levando 2 s: 20 compras em andamento ao mesmo tempo.

AO CONTRÁRIO

50 threads, compras de 2 s: no máximo 25 compras por segundo.

Para caber mais compras por segundo, o que dá para mudar?

07

Teste de carga

// 07 · TESTE DE CARGA

Simular a multidão antes que ela chegue

O QUE É

Usuários de mentira

Um programa, o k6, faz o papel de milhares de pessoas usando o site.

A SUBIDA

Aos poucos

A carga cresce em degraus. Em cada um, medimos se o site continua de pé.

O PICO

De uma vez

Depois, a estreia: muita gente chegando ao mesmo tempo, por alguns segundos.

// 07 · TESTE DE CARGA

Quem aparece no dia da estreia

CURIOSOS

7 em cada 10

Olham a programação e o mapa de assentos, e vão embora.

COMPRADORES

3 em cada 10

Escolhem os assentos e compram. Desistem se demorar demais.

MUITO ENGAJADOS

Não desistem

Tentam de novo até conseguir comprar.

ROBÔS

Cambistas

Tentam comprar o máximo que der, o mais rápido possível.

Quando um degrau conta como “aguentou”

PÁGINAS	COMPRAS	ERROS	RECUSADOS
95% em até 2 s	95% em até 5 s	Menos de 1%	Menos de 1%

O máximo que o sistema aguenta é o último degrau em que tudo isso valeu.

08

Containers e limites de hardware

Cada peça do sistema num container

IMAGEM

O programa e tudo de que ele precisa para rodar, num pacote.

CONTAINER

A imagem rodando, isolada, com um limite de CPU e de memória.

COMPOSE

Um arquivo que descreve todos os containers do sistema. Sobem juntos.

DOCKER-COMPOSE.YML

```yaml
ingressa:
  build: .
  deploy:
    resources:
      limits:
        cpus: "1.0"
        memory: 1G
postgres:
  image: postgres:16-alpine
```

A regra da tarde: um orçamento fixo

2 CPUs

Para tudo o que é do sistema: backend, banco e o que mais entrar.

2 GB

De memória, divididos entre as mesmas peças.

fora

O cinema, o gateway, o e-mail e o teste não contam: não são nossos.

Colocar uma peça nova é tirar CPU e memória de outra.

// PARTE 2

O protótipo

Um sistema de venda de ingressos, uma grande estreia, e uma mudança de cada vez.